



FACULTAD DE CIENCIAS
FÍSICAS Y MATEMÁTICAS
UNIVERSIDAD DE CHILE

Convolutional RNN For RUL Prediction in Mechanical Systems

Miembros de la comisión:

Enrique López Droguett, Viviana Meruane Naranjo, Patricio Loncomilla Zambrana

Nicolas Oyharçabal Astorga

30 de noviembre de 2018

Contenidos

Introducción

Antecedentes

Metodología

Resultados y Discusión

Conclusiones

Anexos

Referencias

Convolutional Recurrent Neural Networks For Remaining Useful Life Prediction in Mechanical Systems

Introducción

Introducción

Motivación

La predicción de la vida útil remanente de un sistema mecánico disminuye el riesgo a fallas catastróficas y los costos de mantención. Ejemplo:



Figura: Falla catastrófica avión 777, The Seattle Times. [1].

Introducción

Motivación

Falla catastrófica




Figura: Falla catastrófica avión 777, The Seattle Times. (Imagen modificada [1]).

Introducción

Objetivo general

Encontrar la mejor opción de red neuronal recurrente convolucional para la estimación de RUL en un sistema mecánico.

Objetivos específicos

- Estudiar modificación de la base de datos.
- Estudiar la aplicación de la Convolución en una serie de tiempo.

Alcances

Programación y puesta en marcha de:

- **ConvLSTM**
- **ConvLSTM Codificadora-Decodificadora**
- ConvJANET
- ConvJANET Codificadora-Decodificadora

Alcances

Programación y puesta en marcha de:

- **ConvLSTM**
- **ConvLSTM Codificadora-Decodificadora**
- **ConvJANET**
- **ConvJANET Codificadora-Decodificadora**

Convolutional Recurrent Neural Networks For Remaining Useful Life Prediction in Mechanical Systems

Antecedentes

Antecedentes, estimación de RUL

RUL \Rightarrow Serie de tiempo




Figura: Relación entre una serie de tiempo y la RUL dentro del total de datos en la vida de una máquina. La línea punteada indica la serie de tiempo a la cual se le asocia una RUL.

Antecedentes, estimación de RUL

Una red neuronal puede relacionar ambas cosas,






Figura: Flujo de información y estructura típica de un Perceptrón. [5].

Antecedentes, redes neuronales



Antecedentes, redes neuronales

Podemos unir muchos perceptrones,





Figura: Perceptrón de múltiples capas para regresión logística.


Antecedentes, redes neuronales




Antecedentes, redes neuronales



Antecedentes, redes neuronales



Antecedentes, redes neuronales



Antecedentes, redes neuronales

Retropropagación [10],




Figura: Superficie creada por distintas posibilidades de pesos y un error determinado.

Los optimizadores ajustan los pesos

- Cuanto se ajusta, $\Delta w_{ij} = -\eta \frac{\partial E_n}{\partial w_{ij}}$.
- Cómo se ajusta, $w_{ij} = w_{ij} + \Delta w_{ij}$.

Antecedentes, redes neuronales

Redes Neuronales Convolucionales [6],

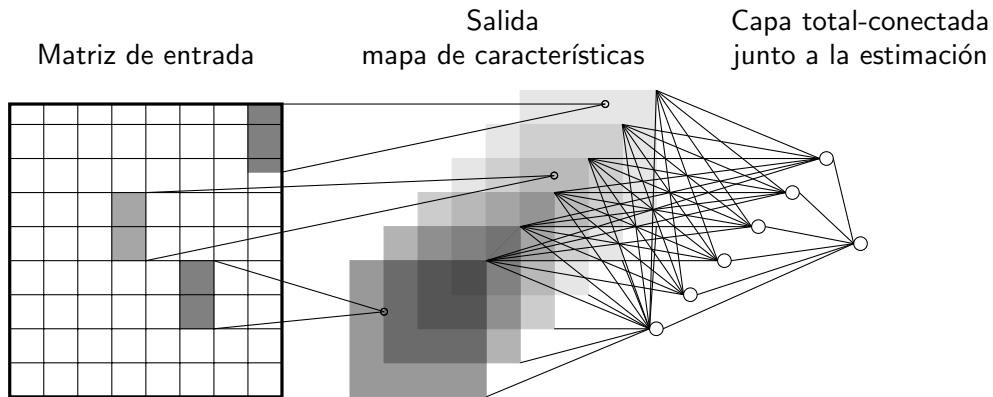


Figura: Modelo estándar de aplicación de redes neuronales convolucionales.

Antecedentes, redes neuronales

Redes neuronales recurrentes ([14] y [15]),




Figura: Célula de red recurrente. Grafo cíclico típico (a) que puede ser desplagado en (b) como grafo acíclico.

Antecedentes, redes neuronales

Redes neuronales recurrentes, LSTM [7],




Figura: Flujo de información en célula LSTM.

Antecedentes, redes neuronales

Redes neuronales recurrentes, JANET [9],




Figura: Flujo de información en JANET.

Antecedentes, redes neuronales recurrentes convolucionales

Aplicable de forma directa similar a una CNN,

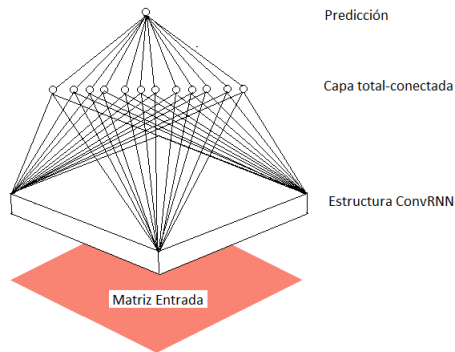


Figura: Aplicación directa de una ConvRNN para la predicción.

Antecedentes, redes neuronales recurrentes convolucionales

Como Codificadora-Decodificadora ([8], [12] y [13]),




Figura: Aplicación de ConvRNN como Codificadora-Decodificadora para la predicción.

Turbofan




Figura: Descripción de partes de un turbofan donde se especifica el ducto de bypass. [2].

C-MAPSS [11]

- Datos como velocidad, presión, temperatura, etc.
- Ruido blanco.
- Operación y fallas.
- Cantidad de datos.

C-MAPSS [11]

- Datos como velocidad, presión, temperatura, etc.
- Ruido blanco.
- Operación y fallas.
- Cantidad de datos.

C-MAPSS [11]

- Datos como velocidad, presión, temperatura, etc.
- Ruido blanco.
- Operación y fallas.
- Cantidad de datos.

C-MAPSS [11]

- Datos como velocidad, presión, temperatura, etc.
- Ruido blanco.
- Operación y fallas.
- Cantidad de datos.

Antecedentes, Medición de exactitud

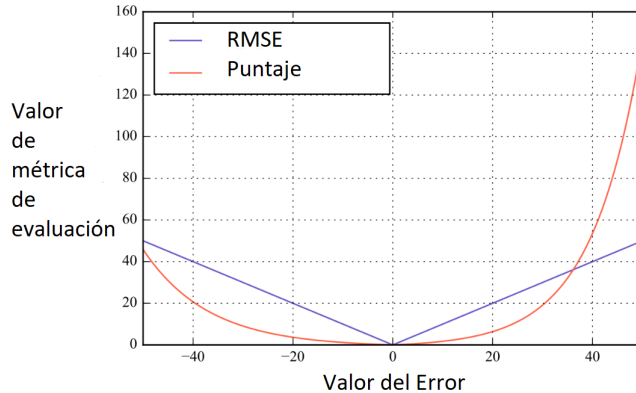



Figura: Asignación de puntaje y exactitud de un modelo según su error. [11].

Convolutional Recurrent Neural Networks For Remaining Useful Life Prediction in Mechanical Systems

Metodología

Metodología, Uso de bases de datos



Metodología, Preprocesamiento de datos

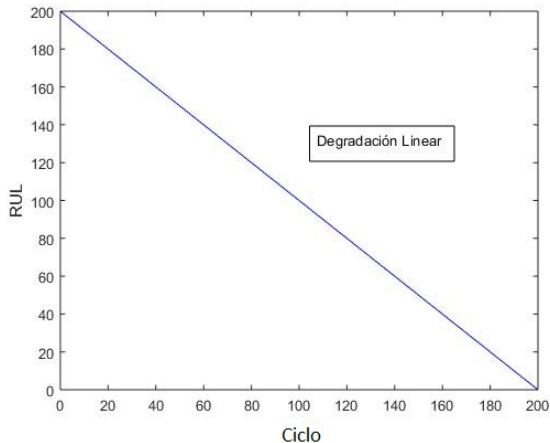


Figura: RULs de bases de datos sin modificar.

Metodología, Preprocesamiento de datos

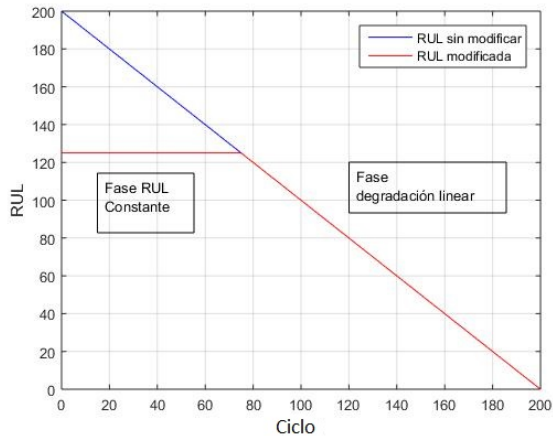


Figura: RULs de bases de datos modificadas.

Convolutional Recurrent Neural Networks For Remaining Useful Life Prediction in Mechanical Systems

Resultados y Discusión

Resultados, Histogramas

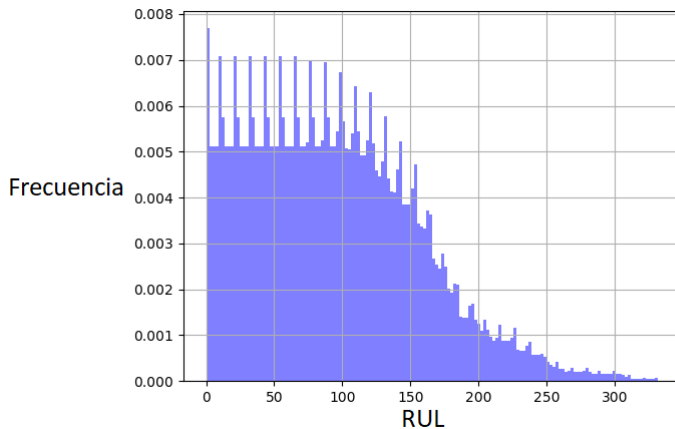


Figura: Histograma de RULs sobre set FD001.

Resultados, Mejores modelos




Figura: Modelo recurrente convolucional obtenido.

Resultados

Modelo	FD004		
	RMSE	Puntaje	Tiempo entre. (s)
ConvJANET	19,55 \pm 0,3	2.259,53 \pm 185,71	255,40 \pm 0,51
ConvJANET C-D	19,15 \pm 0,28	2282,23 \pm 226,58	490,95 \pm 0,63
ConvLSTM	20,75 \pm 0,81	2.513,57 \pm 287,81	266,11 \pm 1,51
ConvLSTM C-D	19,53 \pm 0,23	2316,28 \pm 180,84	615,03 \pm 0,65

Cuadro: ConvLSTM, ConvJANET y sus variedades Codificadora-Decodificadora evaluadas en FD004.

Red convolucional profunda (estado del arte [4])

RMSE: media de 23,31 \pm 0,39

Puntaje: media de 12.466 \pm 853

Resultados

Modelo	FD004		
	RMSE	Puntaje	Tiempo entre. (s)
ConvJANET	19,55 \pm 0,3	2.259,53 \pm 185,71	255,40 \pm 0,51
ConvJANET C-D	19,15 \pm 0,28	2282,23 \pm 226,58	490,95 \pm 0,63
ConvLSTM	20,75 \pm 0,81	2.513,57 \pm 287,81	266,11 \pm 1,51
ConvLSTM C-D	19,53 \pm 0,23	2316,28 \pm 180,84	615,03 \pm 0,65

Cuadro: ConvLSTM, ConvJANET y sus variedades Codificadora-Decodificadora evaluadas en FD004.

Red convolucional profunda (estado del arte [4])

RMSE: media de 23,31 \pm 0,39

Puntaje: media de 12.466 \pm 853

Resultados, Ajuste de ConvJANET Codificadora-Decodificadora en FD003

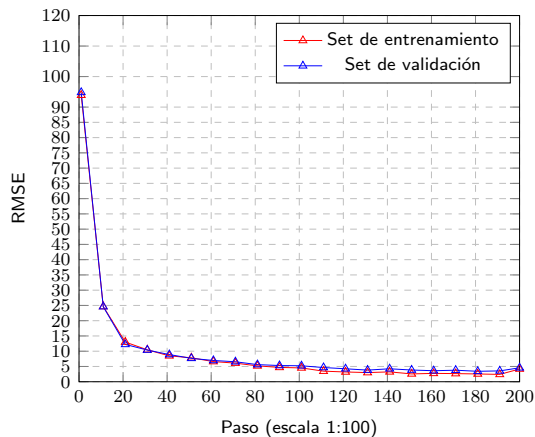


Figura: Exactitud en sets de validación y entrenamiento en cada paso de entrenamiento para ConvJANET Codificadora-Decodificadora en FD003.

Resultados, Predicciones de ConvJANET Codificadora-Decodificadora en FD003

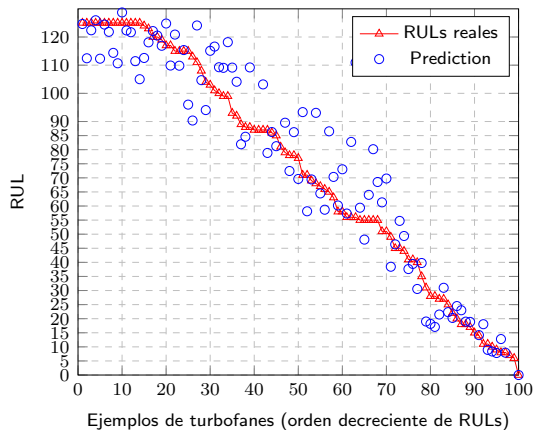


Figura: RULs predichas por ConvJANET Codificadora-Decodificadora en FD003.

Convolutional Recurrent Neural Networks For Remaining Useful Life Prediction in Mechanical Systems

Conclusions

Conclusiones

- Se logran entrenar con éxito todas las redes.
- Modificar las RULs mejora los resultados.
- Capas ConvRNN a veces reemplazables por CNN.
- Mejores resultados en redes tipo JANET Convolutacional.
- JANET Convolutacional Codificadora-Decodificadora es la mejor red.

Conclusiones

- Se logran entrenar con éxito todas las redes.
- Modificar las RULs mejora los resultados.
- Capas ConvRNN a veces reemplazables por CNN.
- Mejores resultados en redes tipo JANET Convolutacional.
- JANET Convolutacional Codificadora-Decodificadora es la mejor red.

Conclusiones

- Se logran entrenar con éxito todas las redes.
- Modificar las RULs mejora los resultados.
- Capas ConvRNN a veces reemplazables por CNN.
- Mejores resultados en redes tipo JANET Convolutacional.
- JANET Convolutacional Codificadora-Decodificadora es la mejor red.

Conclusiones

- Se logran entrenar con éxito todas las redes.
- Modificar las RULs mejora los resultados.
- Capas ConvRNN a veces reemplazables por CNN.
- Mejores resultados en redes tipo JANET Convolutacional.
- JANET Convolutacional Codificadora-Decodificadora es la mejor red.

Conclusiones

- Se logran entrenar con éxito todas las redes.
- Modificar las RULs mejora los resultados.
- Capas ConvRNN a veces reemplazables por CNN.
- Mejores resultados en redes tipo JANET Convolutacional.
- JANET Convolutacional Codificadora-Decodificadora es la mejor red.

Conclusiones

- Se logran entrenar con éxito todas las redes.
- Modificar las RULs mejora los resultados.
- Capas ConvRNN a veces reemplazables por CNN.
- Mejores resultados en redes tipo JANET Convolutacional.
- JANET Convolutacional Codificadora-Decodificadora es la mejor red.

Convolutional Recurrent Neural Networks For Remaining Useful Life Prediction in Mechanical Systems

Anexos

Anexos A

Index	Description	Variable name	Units
1	Physical fan speed	Nf	RPM
2	Physical core speed	Nc	RPM
3	Engine pressure ratio (P50/P2)	EPR	--
4	Total pressure at fan outlet	P21	psia
5	Total temperature at fan outlet	T21	R
6	Total pressure at LPC outlet	P24	psia
7	Total temperature at LPC outlet	T24	R
8	Total pressure at HPC outlet	P30	psia
9	Total temperature at HPC outlet	T30	R
10	Total pressure at burner outlet	P40	psia
11	Total temperature at burner outlet	T40	R
12	Total pressure at HPT outlet	P45	psia
13	Total temperature at HPT outlet	T48	R
14	Total pressure at LPT outlet	P50	psia
15	Total temperature at LPT outlet	T50	R
16	Fan flow	W21	pps
17	Net thrust	Fn	lbf
18	Gross thrust	Fg	lbf
19	Fan stall margin	SmFan	%
20	LPC stall margin	SmLPC	%
21	HPC stall margin	SmHPC	%
22	Corrected fan speed	NfR	RPM
23	Corrected core speed	NcR	RPM
24	Total pressure in bypass-duct	P15	Psia
25	Percent corrected fan speed	PCNfR	%
26	Static pressure at HPC outlet	Ps30	psia
27	Ratio of fuel flow to Ps30	Phi	pph/psia

Figura: Sensores o variables de salida de software C-MAPSS. [3].

Ecuaciones LSTM [7],

$$i_t^j = \sigma(W_i \cdot x_t + U_i \cdot h_{t-1} + V_i \cdot c_{t-1} + b_i)^j \quad (1)$$

$$f_t^j = \sigma(W_f \cdot x_t + U_f \cdot h_{t-1} + V_f \cdot c_{t-1} + b_f)^j \quad (2)$$

$$\bar{c}_t^j = \tanh(W_c \cdot x_t + U_c \cdot h_{t-1} + b_c)^j \quad (3)$$

$$c_t^j = f_t^j \cdot c_t^j + i_t^j \cdot \bar{c}_t^j \quad (4)$$

$$o_t^j = \sigma(W_o \cdot x_t + U_o \cdot h_{t-1} + V_o \cdot c_{t-1} + b_o)^j \quad (5)$$

$$h_t^j = o_t^j \cdot \tanh(c_t^j) \quad (6)$$

Ecuaciones ConvLSTM [8],

$$i_t^j = \sigma(W_i * X_t + U_i * H_{t-1} + V_i \circ C_{t-1} + b_i)^j \quad (7)$$

$$f_t^j = \sigma(W_f * X_t + U_f * H_{t-1} + V_f \circ C_{t-1} + b_f)^j \quad (8)$$

$$\bar{C}_t^j = \tanh(W_c * x_t + U_c * h_{t-1} + b_C)^j \quad (9)$$

$$C_t^j = f_t^j \circ C_t^j + i_t^j \circ \bar{C}_t^j \quad (10)$$

$$o_t^j = \sigma(W_o * X_t + U_o * H_{t-1} + V_o \circ C_{t-1} + b_o)^j \quad (11)$$

$$H_t^j = o_t^j \cdot \tanh(C_t^j) \quad (12)$$

Ecuaciones JANET [9],

$$f_t^j = \sigma(W_f * x_t + U_f * h_{t-1} + b_f)^j \quad (13)$$

$$c_t^j = f_t^j \odot c_t^j + (1 - f_t^j) \odot \tanh(W_c \cdot x_t + U_c \cdot h_{t-1} + b_c)^j \quad (14)$$

$$h_t^j = c_t^j \quad (15)$$

Ecuaciones ConvJANET

$$f_t^j = \sigma(W_f * X_t + U_f * H_{t-1} + b_f)^j \quad (16)$$

$$C_t^j = f_t^j \odot C_t^j + (1 - f_t^j) \odot \tanh(W_c * X_t + U_c * H_{t-1} + b_c)^j \quad (17)$$

$$H_t^j = C_t^j \quad (18)$$

Convolutional Recurrent Neural Networks For Remaining Useful Life Prediction in Mechanical Systems

Referencias

Referencias



[1] The Seattle Times

Probe of 777 engine's explosive failure pinpoints its origin, 2015



[2] Turbofan, relación de Bypass

Imagen tomada de

:https://www.grc.nasa.gov/www/k-12/Missions/Jim/Project2_act.htm,
consultada 06-09-2018)



[3] NASA STI Program

**User's Guide for the Commercial Modular Aero-Propulsion System
Simulation, Version 2, 2012**



[4] Li, Xiang and Ding, Qian and Sun, Jian-Qiao

**Remaining Useful Life Estimation in Prognostics Using Deep Convolution
Neural Networks , 2017**

Referencias



[5] F. Rosenblatt

The Perceptron, 1958



[6] LeCun, Yann and Bernhard E. Boser and John S. Denker and Donnie Henderson and R. E. Howard and Wayne E. Hubbard and Lawrence D. Jackel

Handwritten Digit Recognition with a Back-Propagation Network, 1990



[7] Hochreiter, Sepp and Schmidhuber, Jürgen

Backpropagation through time: what it does and how to do it, 1997



[8] Xingjian Shi and Zhourong Chen and Hao Wang and Dit-Yan Yeung and Wai-Kin Wong and Wang-chun Woo

Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting , 2015

Referencias



[9] Jos van der Westhuizen and Joan Lasenby

The unreasonable effectiveness of the forget gate , 2018



[10] Werbos, Paul

Backpropagation through time: what it does and how to do it, 1990



[11] A. Saxena

damage propagation modeling for aircraft engine run-to-failure simulation, 2008



[12] Srivastava, Nitish and Mansimov, Elman and Salakhutdinov, Ruslan

Unsupervised Learning of Video Representations Using LSTMs, 2015



[13] Sutskever, Ilya and Vinyals, Oriol and Le, Quoc V

Sequence to Sequence Learning with Neural Networks, 2014

Referencias



[14] Mikolov, Tomas and Karafiát, Martin and Burget, Lukás and Cernocký, Jan and Khudanpur, Sanjeev

Recurrent neural network based language model, 2010



[15] Sutskever, Ilya and Vinyals, Oriol and Le, Quoc V

Generating Sequences With Recurrent Neural Networks, 2013